



講義のまとめ：因果関係の推定と操作変数法

第1部：因果関係の推定

まず前半は、ある介入（例：職業訓練）が結果（例：賃金）にどのような影響を与えるか、その「因果関係」をどうして調べるか、という話でした。

1. 基本的な枠組み：潜在的結果モデル

- 潜在的結果（Potential Outcome）：
 - 介入を受けた場合の結果を y_{-1} 、受けなかった場合の結果を y_0 と定義します。これはあくまで「潜在的」な変数です。
 - 例えば、 i さんが訓練を受けたら ($D_i=1$) $y_i = y_{\{1i\}}$ が観測され、 $y_{\{0i\}}$ は観測されへん。逆に訓練を受けへんかったら ($D_i=0$) $y_i = y_{\{0i\}}$ が観測され、 $y_{\{1i\}}$ は観測されへん。
 - この関係は、一つの式 $y_i = (1-D_i)y_{\{0i\}} + D_i y_{\{1i\}}$ (式73) とも書けます。
- 推定したい指標：
 - ATE (Average Treatment Effect; 平均処置効果)：
 - 集団全体の平均的な効果 $ATE = E[y_{-1} - y_0]$ (式68)。
 - これが0より大きければ、介入には平均的に効果があるっちゅうことです。
 - ATT (Average Treatment Effect on the Treated; 処置群の平均処置効果)：
 - 介入を「受けた人たち」における平均的な効果 $ATT = E[y_{-1} - y_0 | [span_6](start_span)D=1]$ 。
 - ATU (Average Treatment Effect on the Untreated)：
 - 介入を「受けなかった人たち」が、もし受けていたらどうやったか、という効果 $E[y_{-1} - y_0 | [span_7](start_span)D=0]$ も定義上は考えられます。

2. 推定方法 (1): RCT(ランダム化比較試験)

一番ありがたい、理想的な状況です。

- 仮定：介入 D （職業訓練を受けるかどうか）と、潜在的結果 y_{-1}, y_0 が独立であること。
 - これは「この人は効果が出そう」とか「この人はあかんそう」とか関係なく、サイコロを振るみたいにランダムに介入を割り当てた状況（RCT）で成立します。
- 推定：
 - この仮定があると、 $E[y_{-1}] = E[y_{-1} | D=1] = E[y | [span_11](start_span)D=1]$ となります。
 - 同様に、 $E[y_0] = E[y_0 | D=0] = E[y | [span_12](start_span)D=0]$ となります。
 - その結果、ATEは「介入を受けた人の平均 y 」と「受けなかった人の平均 y 」の単純な差で推定できます。 $ATE = E[y | D=1] - E[y | D=0]$ (式81)
- 回帰分析での推定：
 - $y_i = \beta_0 + \tau D_i + u_i$ (式84の変形) という回帰式を考えます。
 - RCTの仮定（ y_{-1}, y_0 が D と独立）があれば、誤差項 u と D が直交し ($E[u|D]=0$)、OLS(最小二乗法)で推定した係数 τ が ATE と一致します。

3. 推定方法 (2): RCT以外(交絡変数がある場合)

現実の社会科学ではRCTは難しく、介入 D と結果 y の両方に影響を与える交絡変数 X （例：訓練前

の収入や能力)が存在します。

- 必要な2つの仮定:
 1. 条件付き独立性の仮定 (**CIA**): X の値を固定すれば(X を条件づければ)、 D と y_1 , y_0 は独立になる。
 2. オーバーラップの仮定: どんな X の値であっても、介入を受ける確率 $P(D=1|X)$ が 0 や 1 にはならへん。(※後述の傾向スコア法で分母が0になるのを防ぐため)

この仮定のもとで、主に3つの推定方法が紹介されました。

① 回帰による調整 (Regression Adjustment)

- 考え方:
 - $M_1(X) = E[y_1 | X=x]$ (X の値が x の人の y_1 の期待値)
 - $M_0(X) = E[y_0 | X=x]$ (X の値が x の人の y_0 の期待値)
 - これらを推定できれば、 $ATE = E_X [M_1(X) - M_0(X)]$ として、全 X について平均すれば ATE が出ます。
- 推定ステップ:
 1. $D=1$ (介入あり)のグループだけを使って、 y を X に回帰し、 $M_1(X)$ を推定します。
 2. $D=0$ (介入なし)のグループだけを使って、 y を X に回帰し、 $M_0(X)$ を推定します。
 3. 推定した $\hat{M}_1(X)$ と $\hat{M}_0(X)$ の差を、全サンプルで平均します。
- 特徴:
 - y と X の関係(例: 線形 $y = \alpha + \beta X$)を正しく仮定(特定化)する必要があります。これが間違うと推定結果も間違うてしまいます。
 - ただし、オーバーラップの仮定は不要です。

② 傾向スコア・マッチング (Propensity Score Matching / IPW)

- 傾向スコア (**Propensity Score**): $P(X) = P(D=1 | X=x)$ 。
 - その人の X の値に基づき、介入を受ける確率を定義したものです。
- 考え方:
 - $E[y_1]$ と $E[y_0]$ を、傾向スコアの逆数で重み付けする(IPW: Inverse Probability Weighting)ことで推定します。
 - 導出の結果、以下の関係が成り立ちます。
 -
 -
 -
- 推定ステップ:
 1. まず $P(X)$ を推定する必要があります。データには $P(X)$ はないので、プロビットモデルやロジットモデルを使って D を X で説明し、予測確率 $\hat{P}(X)$ を計算します。
 2. $ATE = E[\frac{D}{\hat{P}(X)} - \frac{1-D}{1-\hat{P}(X)}]$ (式101, 102) をサンプルの平均で計算します。
- 特徴:
 - 回帰調整と違い、 y と X の関数形(M_1 , M_0)を仮定せんとえのが強みです。
 - ただし、傾向スコア $P(X)$ のモデル(プロビットなど)を正しく特定化する必要があります。

③ 二重にロバストな推定法 (Doubly Robust Estimation)

- 考え方: 上記2つの「ええとこ取り」をする方法です。
 - 回帰調整で使うモデル (M_1 , M_0)
 - 傾向スコアで使うモデル ($P(X)$)
 - この**「どっちか一方」が正しく特定化されていれば**、 ATE を正しく推定できる、という非

常に頑健(ロバスト)な方法です。

- 推定:
 - (講義では複雑な式 (式105, 106) が提示されました)
 - もし **M** のモデルが間違っていても **P** が正しければ、追加で足した補正項の期待値が0になり、結果的に傾向スコア推定量と一致して、正しい値に収束します。
 - もし **P** のモデルが間違っていても **M** が正しければ、こちらも上手いこと調整され、正しい値に収束します。

4. 因果推論の限界

- 外的妥当性 (**External Validity**): 京都市での職業訓練の効果が、北海道やアフリカと同じとは限らへん、という問題です。
- 一般均衡効果 (**General Equilibrium Effect**):
 - 実験的に「一部の人」に訓練した場合の効果と、制度として「日本全国民」に訓練した場合の効果は違う可能性があります。
 - みんなが訓練を受けたら、技能の希少価値がなくなって賃金が上がらんかもしけん、ということです。

第2部: 操作変数法 (IV法)

後半は、OLS(最小二乗法)が使えへん状況、すなわち説明変数 X と誤差項 U が相関してしまう「内生性」がある場合に、どうして正しい係数を推定するか、という話でした。

1. なぜ内生性が起きるのか?

- 欠落変数 (**Omitted Variable**): 本当はモデルに必要な変数 Z がデータではなく、モデルから欠落している場合。 Z が X とも y とも相関していると、 Z の影響が誤差項 U に含まれてしまい、 X と U が相関します。
- 同時方程式 (**Simultaneity**): 需要と供給のように、 y と X がお互いに影響しあって決まる場合。
- 測定誤差 (**Measurement Error**): 説明変数 X に測定誤差がある場合。

2. 測定誤差(詳細)

- 真のモデル: $y = \beta_0 + \beta_1 X^* + U$ (X^* は真の値)
- 観測されるデータ: $X = X^* + V$ (V は測定誤差)
- 推定するモデル: 観測できる X を使うと、式は $y = \beta_0 + \beta_1 X + (\beta_1 V - \beta_1 V)$ となります。
- 問題点: 新しい誤差項 $\epsilon = (U - \beta_1 V)$ と、説明変数 $X = (X^* + V)$ は、共通の V を含んでいるため、必ず相関してしまいます ($Cov(X, \epsilon) \neq 0$)。
- 結果: OLSで推定すると、 β_1 の推定値は間違った値(過小推定)になります。

3. 操作変数 (**Instrumental Variable, IV**) とは?

この内生性の問題を解決するのが「操作変数 Z 」です。

- 操作変数 Z が満たすべき2つの条件:
 1. 関連性 (**Relevance**): Z は、内生変数 X と相関している ($Cov(Z, X) \neq 0$)。
 2. 外生性 (**Exogeneity**): Z は、誤差項 U とは相関していない ($Cov(Z, U) = 0$)。

- 用語の整理:
 - 内生変数: 誤差項 U と相關する変数(この例では X と Y)。
 - 外生変数: 誤差項 U と相關しない変数(この例では Z)。

4. IV推定量の導出 (X, Z が各1つの場合)

- 元のモデル $y = \beta_0 + \beta_1 X + U$ の両辺と Z の共分散 $\text{Cov}(Z, \cdot)$ をとります。
 $\text{Cov}(Z, y) = \text{Cov}(Z, \beta_0 + \beta_1 X + U)$
- 共分散の性質から、 $\text{Cov}(Z, y) = \beta_1 \text{Cov}(Z, X) + \text{Cov}(Z, U)$ となります。
- ここでIVの条件を使います。
 - 外生性 ($\text{Cov}(Z, U) = 0$) より、第2項は0になります。
 - 関連性 ($\text{Cov}(Z, X) \neq 0$) より、 $\text{Cov}(Z, X)$ は0ではないので、両辺を割ることができます。
- IV推定量:** $\hat{\beta}_1 = \frac{\text{Cov}(Z, y)}{\text{Cov}(Z, X)}$
- データ(標本)からは、それぞれの標本共分散 S_{ZY} と S_{ZX} の比として推定できます。
 $\hat{\beta}_1 = \frac{S_{ZY}}{S_{ZX}}$

5. 2段階最小二乗法 (TSLS or 2SLS)

IV推定量を計算する、もう一つの(そしてより一般的な)方法です。

- 考え方: 内生変数 X のうち、 Z と相關している「良い部分」(外生的な部分)だけを抽出して回帰に使う、という考え方です。
- 推定ステップ:
 - 第1段階 (1st Stage):**
 - 内生変数 X を、操作変数 Z にOLS回帰します。
 - この回帰から、 X の予測値 $\hat{X} = \hat{\pi}_0 + \hat{\pi}_1 Z$ を作ります。
 - この \hat{X} は、 X の変動のうち Z で説明できる「良い」部分だけを取り出したものと解釈できます。
 - 第2段階 (2nd Stage):**
 - 元の y を、元の X の代わりに予測値 \hat{X} を使ってOLS回帰します。
 - この時に得られた係数 $\hat{\beta}_1$ が、TSLS推定量です。
- 特徴:
 - X と Z が1変数ずつの場合、このTSLSで得られる推定量は、先に導出したIV推定量 ($\frac{S_{ZY}}{S_{ZX}}$) と完全に一致します。

連絡事項

- 来週月曜日に中間試験。
- 範囲は今日の講義(操作変数法)まで。
- 持ち込みは一切なし。

こんな感じで、講義の流れと重要なポイントを詳細に追ってみました。どういでしょうか？