計量経済学講義：二項選択モデルと最尤推定法の超詳細まとめ

第1部：二項選択モデルの基礎

1.1 問題設定

従来の回帰分析では、被説明変数Yは連続変数（実数値）を取っていた。しかし、今回扱うのは**Yが0か1のみを取る二項変数（ダミー変数）**の場合である。

具体例：

- 既婚女性が働くかどうか（1=働く、0=働かない）
- 生活保護を受給しているかどうか
- ある製品を購入するかどうか

0と1自体には本質的な意味はなく、2つの選択肢のどちらかを数値で表現しているだけである。

第2部：線形確率モデル（Linear Probability Model: LPM）

2.1 モデルの定式化

従来の線形回帰モデルをそのまま適用する考え方：

$$E[Y|X] = X'\beta$$

Yが0か1しか取らないとき、期待値を計算すると：

$$E[Y|X] = 1 \times P(Y=1|X) + 0 \times P(Y=0|X) = P(Y=1|X)$$

したがって、線形確率モデルでは：

$$P(Y=1|X) = X'\beta$$

2.2 係数βの解釈

線形確率モデルにおけるβは、**Xを1**単位変化させたときの**Y=1**の確率の変化を表す。

従来の連続変数の場合：βはXの1単位変化に対するYの平均的変化 二項変数の場合：βはXの1単位変化に対するY=1の確率の変化

2.3 推定方法

通常の最小二乗法（OLS）をそのまま適用可能。

2.4 線形確率モデルの重大な問題点

確率が**0-1**の範囲に収まらない問題：

Xの値域が広い場合（例：正規分布に従うなど）：

- Xが非常に大きい値を取ると、P(Y=1|X) > 1 となる
- Xが非常に小さい（負の方向に大きい）値を取ると、P(Y=1|X) < 0 となる

これは論理的に不整合であり、確率の定義に反する。

第3部：プロビットモデル（Probit Model）

3.1 モデルの定式化

線形確率モデルの問題を解決するため、標準正規分布の累積分布関数**Φ**を導入：

$$P(Y=1|X) = \Phi(X'\beta)$$

ここで、Φは標準正規分布の累積分布関数：

$$\Phi(z) = \int_{-\infty}^{z} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

3.2 なぜこれで問題が解決するか

累積分布関数Φの性質：

- z → -∞ のとき、Φ(z) → 0
- z → +∞ のとき、Φ(z) → 1
- 常に 0 < Φ(z) < 1

したがって、X'βがどのような値を取っても、確率は必ず0と1の間に収まる。

3.3 欠落変数バイアス

プロビットモデルでも、必要な説明変数を入れていないと欠落変数バイアスが生じる。これは通常の回帰分析と同様の問題である。

3.4 限界効果（Marginal Effect）の計算

プロビットモデルは非線形モデルなので、βの解釈が線形モデルとは異なる。

限界効果の導出（合成関数の微分）:

$$\frac{\partial P(Y=1|X)}{\partial X_k} = \phi(X'\beta) \cdot \beta_k$$

ここで、φ（小文字）は標準正規分布の確率密度関数:

$$\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$$

3.5 限界効果の重要な特徴

限界効果は**X**の値に依存する

どの水準から変化させるかによって効果が異なる。これは線形モデルとの大きな違いである。

3.6 限界効果の報告方法（3つの代表的手法）

論文で限界効果を報告する際の標準的な方法:

① 平均限界効果（**Average Marginal Effect: AME**） $$\frac{1}{N} \sum_{i=1}^{N} \phi(X_i'\hat{\beta}) \cdot \hat{\beta}_k$$

各個人について限界効果を計算し、その平均を取る。

② 代表値での限界効果（**Marginal Effect at the Mean: MEM**） $$\phi(\bar{X}'\hat{\beta}) \cdot \hat{\beta}_k$$

説明変数の平均値における限界効果を計算。

③ 中央値での限界効果

説明変数の中央値（メディアン）で評価。

第4部：ロジットモデル（Logit Model）

4.1 モデルの定式化

プロビットモデルの標準正規分布関数Φの代わりに、ロジスティック分布の累積分布関数**Λ**を使用:

$$P(Y=1|X) = \Lambda(X'\beta) = \frac{\exp(X'\beta)}{1 + \exp(X'\beta)} = \frac{1}{1 + \exp(-X'\beta)}$$

4.2 プロビットとロジットの比較

形状の類似性: 両者の累積分布関数は非常によく似た形状をしている。分散やロケーションパラメータを適切に調整すると、グラフ上でほとんど区別がつかない。

計算上の利点:

- ロジスティック分布:閉形式で表現可能(明示的に書ける)
- 正規分布:積分形式でしか表現できない(無限級数展開が必要)

歴史的には、計算機が発達する前はロジットモデルの方が計算しやすかった。現在はどちらも瞬時に計算可能。

4.3 推定結果の違い

同じデータに両モデルを当てはめると:

- 推定値は異なる
- しかし、結果は非常によく似通っている
- 実務上、どちらを使っても大きな違いはない

4.4 IIA問題(Independence of Irrelevant Alternatives)

ロジットモデルを**3**つ以上の選択肢に拡張した場合の問題:

ロジットモデルでは、2つの選択肢間の確率の比が、他の選択肢の存在に関係なく一定であるという制約が自動的に課される。

具体例(通勤手段の選択):

- 元々:車50%、バス50%
- 新しいバス会社が参入した場合

直感的には:車50%、バスA 25%、バスB 25%(バス同士で競合)

しかしIIA制約の下では:車とバスAの比率は1:1のまま維持される必要があり、不自然な結果となる。

対処法: 3つ以上の選択肢がある場合は、プロビットモデル(多項プロビット)の方が適切な場合がある。

第5部：3つのモデルの比較まとめ

モデル	定式化	特徴
線形確率モデル	P(Y=1|X) = X'β	簡単だが確率が0-1を超える問題
プロビットモデル	P(Y=1|X) = Φ(X'β)	標準正規分布関数を使用
ロジットモデル	P(Y=1|X) = Λ(X'β)	ロジスティック分布関数を使用

どのモデルを使うべきか

- 明確な基準はない
- プロビットとロジットの選択は、どちらの関数形がデータにより適合するかの問題
- モデル選択基準を使用することも可能
- 実質的には大差ないため、使いやすい方を選ぶことも多い
- 線形確率モデルは確率の範囲問題があるため、通常はプロビットかロジットを使用

線形確率モデルの利点

二項変数が説明変数の場合、線形確率モデルの係数βは**平均処置効果（Average Treatment Effect: ATE）**に一致する：

$$\beta = E[Y|X=1] - E[Y|X=0]$$

第6部：最尤推定法（Maximum Likelihood Estimation: MLE）

6.1 基本的な考え方

尤度関数の定義： 得られたデータが観察される確率（または確率密度）を、パラメータの関数として見たもの。

最尤推定の原理： 尤度関数を最大にするようにパラメータを決定する。

直感的理解：「実際に観察されたデータが得られる確率が最も高くなるようにパラメータの値を決める」

背後にある考え方：起こりやすいことが起こったと考えるのが自然。

コイン投げの例：

- 100回投げて70回表が出た

- 表の確率は1/2ではなく、7/10と推定するのが自然
- 「本当は1/2だけど、たまたま70回出た」より「7/10で70回出た」と考える方が自然

6.2 二項分布の場合（説明変数なし）

設定：

- コインを投げる（表=1、裏=0）
- 表が出る確率をpとする
- Y=1のとき確率p、Y=0のとき確率1-p

確率関数の表現：

$$P(Y=y) = p^y (1-p)^{1-y}$$

この式は以下を統一的に表現：

- y=1のとき：$p^1(1-p)^0 = p$
- y=0のとき：$p^0(1-p)^1 = 1-p$

N回の独立な試行の場合：

$$L(p) = \prod_{i=1}^{N} p^{y_i} (1-p)^{1-y_i}$$

6.3 尤度関数と対数尤度関数

データが得られた後の視点の変化：

- データ取得前：Yが変数、pがパラメータ → 確率関数
- データ取得後：Yは既知の数値、pが変数 → 尤度関数

対数変換の理由：積の形は扱いにくいため、単調増加変換である自然対数を取る。

対数の性質：

- $\log(A \times B) = \log(A) + \log(B)$
- $\log(A^B) = B \times \log(A)$

対数尤度関数：

$$\ell(p) = \sum_{i=1}^{N} [y_i \log p + (1-y_i) \log(1-p)]$$

対数変換は単調増加なので、尤度を最大にするpと対数尤度を最大にするpは同じ。

6.4 最尤推定量の導出（説明変数なしの場合）

一階条件：

$$\frac{\partial \ell}{\partial p} = \sum_{i=1}^{N} \left[\frac{y_i}{p} - \frac{1-y_i}{1-p} \right] = 0$$

解：

$$\hat{p} = \bar{Y} = \frac{1}{N} \sum_{i=1}^{N} y_i$$

Yは0か1のみを取るため、$\bar{Y}$は**1が出た比率（標本比率）**に等しい。

コインの例では、表が出た比率が最尤推定量となる。

6.5 プロビットモデルの最尤推定

条件付き尤度関数：

説明変数Xがある場合、P(Y=1|X) = Φ(X'β)となる。

条件付き対数尤度関数：

$$\ell(\beta) = \sum_{i=1}^{N} [y_i \log \Phi(X_i'\beta) + (1-y_i) \log(1-\Phi(X_i'\beta))]$$

6.6 条件付き尤度と無条件尤度

厳密な議論：

- 上記は条件付き対数尤度（Xを条件とした）
- 真の尤度は無条件尤度：L(β) × f(X)

実用上の結論： Xの密度関数f(X)がβに依存しなければ、条件付き尤度の最大化と無条件尤度の最大化は同じ結果を与える。

理由：対数を取ると和に分解され、f(X)の部分はβに関する定数となるため。

通常、説明変数Xの分布がβに依存する状況は考えにくいため、条件付き尤度を使用して問題ない。

6.7 数値的最適化

プロビットモデルの一階条件は、線形回帰のように解析的に解けない。

$$\frac{\partial \ell}{\partial \beta} = \sum_{i=1}^{N} \left[\frac{y_i \phi(X_i'\beta)}{\Phi(X_i'\beta)} - \frac{(1-y_i)\phi(X_i'\beta)}{1-\Phi(X_i'\beta)} \right] X_i = 0$$

したがって、数値的な反復計算（ニュートン・ラフソン法など）で解を求める。

現代の統計ソフトウェアでは、コマンド一つで簡単に推定可能。

第7部：最尤推定量の統計的性質

7.1 一致性（Consistency）

定理：最尤推定量$\hat{\beta}$は真のパラメータβ_0に確率収束する。

証明の概略：

1. 対数尤度関数をNで割った$\frac{1}{N}\ell(\beta)$を考える
2. 大数の法則により、これは期待値$E[\ell_i(\beta)]$に確率収束
3. $\hat{\beta}$は$\frac{1}{N}\ell(\beta)$を最大化
4. 収束先の関数の最大点がβ_0であることを示す

直感的理解（グラフによる説明）：

- N=10のときの対数尤度関数
- N=100のときの対数尤度関数
- N→∞のときの極限関数

Nが大きくなるにつれて、対数尤度関数は極限関数に近づき、最大点も真の値に収束する。

7.2 漸近正規性（Asymptotic Normality）

定理：

$$\sqrt{N}(\hat{\beta} - \beta_0) \xrightarrow{d} N(0, I(\beta_0)^{-1})$$

ここで、$I(\beta_0)$はフィッシャー情報行列。

導出の概略：

1. 一階条件：$G(\hat{\beta}) = 0$（Gは対数尤度の一階微分）

2. 真の値β_0の周りでテイラー展開：$$G(\beta_0) + H(\tilde{\beta})(\hat{\beta} - \beta_0) = 0$$（Hは二階微分、ヘシアン）

3. 整理すると：$$\sqrt{N}(\hat{\beta} - \beta_0) = -\left(\frac{1}{N}H(\tilde{\beta})\right)^{-1} \frac{1}{\sqrt{N}}G(\beta_0)$$

4. 中心極限定理により：$$\frac{1}{\sqrt{N}}G(\beta_0) \xrightarrow{d} N(0, Var(G_i(\beta_0)))$$

5. 大数の法則により：$$\frac{1}{N}H(\tilde{\beta}) \xrightarrow{p} E[H_i(\beta_0)]$$

7.3 情報等式（Information Equality）

重要な性質：

$$E\left[-\frac{\partial^2 \ell_i}{\partial \beta \partial \beta'}\right] = E\left[\frac{\partial \ell_i}{\partial \beta} \frac{\partial \ell_i}{\partial \beta'}\right]$$

つまり、ヘシアンの期待値（の符号反転）= スコアの分散

結果：漸近分散は以下のように簡略化される：

$$Var(\sqrt{N}(\hat{\beta} - \beta_0)) = I(\beta_0)^{-1}$$

7.4 漸近分散の2つの推定方法

① ヘシアンに基づく推定（標準的）：

$$\widehat{Var}(\hat{\beta}) = \left(-\frac{1}{N}\sum_{i=1}^{N} H_i(\hat{\beta})\right)^{-1}$$

② 外積（**Outer Product**）に基づく推定（**BHHH**推定量）：

$$\widehat{Var}(\hat{\beta}) = \left(\frac{1}{N}\sum_{i=1}^{N} G_i(\hat{\beta})G_i(\hat{\beta})'\right)^{-1}$$

BHHHはBerndt-Hall-Hall-Hausmanの略。

比較：

- 両方とも一致推定量
- ヘシアンに基づく方が標準的で安定
- BHHH推定量はヘシアンの計算が困難な場合に有用だが、シミュレーションでやや不安定な場合がある

7.5 効率性（Efficiency）

定理：最尤推定量は、一致推定量のクラスの中で最も分散が小さい（漸近的に効率的）。

これは非常に強い性質であり、最尤推定量の重要な利点である。

注意点：効率性は、モデルが正しく特定されている場合に成立。モデルの関数形（プロビットならΦ）が間違っていると、推定量の性質は保証されない。

第8部：モデルの当てはまりの指標

8.1 決定係数R^2の問題

通常の回帰分析で使われるR^2は、二項選択モデルではあまり適切でない。

8.2 ヒットレート（Hit Rate）

考え方：予測値と実際の値がどれだけ一致するかを見る。

予測値の作成：

$$\hat{Y}_i = \begin{cases} 1 & \text{if } \hat{P}_i > 0.5 \ 0 & \text{if } \hat{P}_i \leq 0.5 \end{cases}$$

ここで、$\hat{P}_i = \Phi(X_i'\hat{\beta})$

ヒットレートの計算：

$$\text{Hit Rate} = \frac{1}{N}\sum_{i=1}^{N} (1 - |Y_i - \hat{Y}_i|)$$

Y_iと$\hat{Y}_i$が一致すれば1、不一致なら0となる。

ヒットレートの問題点：

データの95%がY=1の場合、全てY=1と予測するだけで95%のヒットレートが達成できる。これはモデルの良さを反映していない。

8.3 調整済みヒットレート

ナイーブな予測との比較：

$$\bar{Y}_{R0} = \max(\bar{Y}, 1-\bar{Y})$$

これは「多い方を全て予測する」戦略のヒットレート。

調整済み指標：

$$\frac{\text{Hit Rate} - \bar{Y}*{R0}}{1 - \bar{Y}*{R0}}$$

- 分子：実際のヒットレートがナイーブ予測をどれだけ上回るか
- 分母：改善の余地

ナイーブ予測を超えて初めて正の値となり、モデルの付加価値を評価できる。

具体例：

- データの90%がY=1
- ヒットレート90%（全部1と予測）→ 調整済み指標 = 0

- モデルに意味がないことを反映

8.4 擬似決定係数（Pseudo R^2）

① マクファデンのR^2（**McFadden's R^2**）:

$$R^2_{MF} = 1 - \frac{\ell(\hat{\beta})}{\ell_0}$$

ここで:

- $\ell(\hat{\beta})$: 説明変数を含むモデルの対数尤度
- ℓ_0: 定数項のみのモデル（帰無モデル）の対数尤度

帰無モデルの対数尤度:

$$\ell_0 = N_1 \log\left(\frac{N_1}{N}\right) + N_0 \log\left(\frac{N_0}{N}\right)$$

ここで、N_1はY=1の個数、N_0はY=0の個数。

解釈:

- Xが全く意味がない場合: $\ell(\hat{\beta}) \approx \ell_0$ → $R^2 \approx 0$
- Xが非常に有用な場合: $\ell(\hat{\beta})$が0に近づく → $R^2 \to 1$

② 尤度比に基づくR^2:

$$R^2_{LR} = 1 - \frac{L(\hat{\beta})}{L_0} = 1 - \exp(\ell(\hat{\beta}) - \ell_0)$$

考え方は同じだが、対数ではなく尤度そのものの比を使用。

対数尤度が常に負である理由:

- log内の値（確率）は0と1の間
- log関数は(0,1)区間で負の値を取る

したがって、$\ell(\hat{\beta}) < \ell_0 < 0$（両方負、$\hat{\beta}$の方が絶対値が小さい）

第9部: 経済学的解釈

9.1 確率的効用モデル（Random Utility Model）

設定: 2つの選択肢（0と1）に対応する効用:

$$U_0 = X'\beta_0 + \varepsilon_0$$ $$U_1 = X'\beta_1 + \varepsilon_1$$

誤差項$(\varepsilon_0, \varepsilon_1)$は二変量正規分布に従うと仮定。

選択ルール：効用最大化により、$U_1 > U_0$ならY=1を選択。

導出：

$$P(Y=1|X) = P(U_1 > U_0) = P(\varepsilon_0 - \varepsilon_1 < X'(\beta_1 - \beta_0))$$

$\varepsilon_0 - \varepsilon_1$は正規分布の差なので正規分布に従う。

標準化（分散で割る）すると：

$$P(Y=1|X) = \Phi\left(\frac{X'(\beta_1 - \beta_0)}{\sigma_{\varepsilon_0 - \varepsilon_1}}\right) = \Phi(X'\beta^*)$$

これはプロビットモデルの形になる。

9.2 経済学的解釈から得られる洞察

① 係数の意味：推定されるβ^*は、2つの選択肢の効用への影響の差（$\beta_1 - \beta_0$を標準化したもの）を表す。

② 効用水準自体は意味を持たない：効用関数は順序尺度であり、水準の絶対値には意味がない。差のみが意味を持つ。

③ 識別の問題：個々のβ_0とβ_1は識別できず、その差のみが推定可能。

9.3 潜在変数モデル（Latent Variable Model）

設定：観察されない連続変数Y*が存在：

$$Y^* = X'\beta + \varepsilon$$

ここで、$\varepsilon \sim N(0,1)$

観察ルール：

$$Y = \begin{cases} 1 & \text{if } Y^* > 0 \ 0 & \text{if } Y^* \leq 0 \end{cases}$$

導出：

$$P(Y=1|X) = P(Y^* > 0) = P(X'\beta + \varepsilon > 0) = P(\varepsilon > -X'\beta)$$

正規分布の対称性より：

$$= P(\varepsilon < X'\beta) = \Phi(X'\beta)$$

これもプロビットモデルの形になる。

具体例:

- Y* = 真の所得(観察不能)
- Y = 生活保護受給(観察可能、所得が閾値以下なら1)
- 所得は連続的だが、閾値を超えているかどうかのみ観察される

第10部:実務上の注意点まとめ

10.1 モデル選択

状況	推奨モデル
2つの選択肢、通常の分析	プロビットまたはロジット
計算の簡便さ重視	ロジット
3つ以上の選択肢	多項プロビット(IIA問題回避)
平均処置効果の解釈が重要	線形確率モデルも選択肢

10.2 報告すべき項目

1. 推定係数と標準誤差
2. 限界効果(平均限界効果が標準的)
3. 当てはまりの指標(擬似R^2、ヒットレートなど)
4. サンプルサイズと0/1の分布

10.3 限界効果の報告

非線形モデルでは係数の直接的解釈が難しいため、限界効果の報告が重要。3つの方法(AME、MEM、中央値での評価)のいずれかを選択し、明記する。

この講義では、二項選択モデルの理論的基礎から実践的な推定・解釈まで、体系的に学んだ。特に最尤推定法の統計的性質(一致性、漸近正規性、効率性)の理解は、正しい統計的推論を行う上で不可欠である。