計量経済学講義ノート：超詳細まとめ

📚 講義の全体構成

この講義は大きく**2**つのパートに分かれています：

1. 二値選択モデル（**Binary Choice Models**）：プロビット・ロジットモデルの理論と解釈
2. 時系列分析（**Time Series Analysis**）：定常性、自己相関、ARモデルの基礎

第**1**部：二値選択モデル（**Binary Choice Models**）

1. 線形確率モデル（**Linear Probability Model: LPM**）

1.1 基本設定

- 被説明変数**Y**：0か1の二値のみを取る
- 状況例：
  - 働くかどうか
  - 商品を買うかどうか
  - 大学に進学するかどうか

1.2 モデルの定式化

通常の回帰モデルの枠組みで考えると：

$$E[Y|X] = X'\beta$$

Yが0か1しか取らないため、左辺は：

$$E[Y|X] = 1 \times P(Y=1|X) + 0 \times P(Y=0|X) = P(Y=1|X)$$

つまり、**X**を条件とした**Y**の期待値 ＝ **Y=1**となる確率

1.3 線形確率モデルの根本的問題

重大な論理的矛盾：

- 中辺（確率）は必ず**0**と**1**の間になければならない
- しかし右辺 $X'\beta$ は、Xの値によっては0未満や1超の値を取りうる
- 例：Xが正規分布に従う場合、$X'\beta$ が0〜1に収まる保証は全くない

結論：線形確率モデルは論理的に問題がある設定

---

2. プロビットモデル（Probit Model）

2.1 発想

右辺 $X'\beta$ を**0**〜**1**の間に変換する関数を噛ませる

2.2 プロビットモデルの定式化

$$P(Y=1|X) = \Phi(X'\beta)$$

ここで $\Phi(\cdot)$ は標準正規分布の累積分布関数（**CDF**）

2.3 なぜこれで解決するか

- 標準正規分布のCDFは、任意の実数を入力しても必ず**0**〜**1**の値を出力
- これにより確率としての整合性が保たれる

2.4 推定方法

最尤法（Maximum Likelihood Estimation）を使用

講義では尤度関数の導出と一階条件（情報等式）についても触れられている。

---

3. ロジットモデル（Logit Model）

3.1 定式化

$$P(Y=1|X) = \Lambda(X'\beta)$$

ここで $\Lambda(\cdot)$ はロジスティック分布の累積分布関数

3.2 プロビットとの違い

- Φ（標準正規CDF）の代わりに Λ（ロジスティックCDF）を使用
- 実用上、推定結果はプロビットと大きく変わらないことが多い

---

4. 経済モデルからの導出：2つのアプローチ

4.1 アプローチ①：確率的効用モデル（Random Utility Model）

設定

個人が2つの選択肢（例：大学進学する/しない）を持つ意思決定問題

効用関数

- 大学に行く場合の効用：$U_1 = X'\beta_1 + \varepsilon_1$
- 大学に行かない場合の効用：$U_0 = X'\beta_0 + \varepsilon_0$

選択ルール

効用最大化により、$U_1 > U_0$ のとき $Y=1$（大学進学）を選択

確率の導出

$$P(Y=1|X) = P(U_1 > U_0) = P(\varepsilon_0 - \varepsilon_1 < X'(\beta_1 - \beta_0))$$

$\varepsilon_1 - \varepsilon_0$ が標準正規分布に従うと仮定すると：

$$P(Y=1|X) = \Phi(X'\beta^*)$$

ここで $\beta^* = (\beta_1 - \beta_0)/\sigma_{\varepsilon_1}$

→ プロビットモデルが導出される！

ロジットの場合

誤差項がロジスティック分布に従うと仮定すれば、ロジットモデルが導出される

4.2 アプローチ②：潜在変数モデル（Latent Variable Model）

設定

- 潜在変数 Y^*：連続変数だが直接観測できない
- 観測されるのは：Y^* が正かどうかだけ

$$Y^* = X'\beta + U, \quad U \sim N(0,1)$$

$$Y = \mathbf{1}(Y^* > 0)$$

（$\mathbf{1}(\cdot)$ は指示関数：括弧内が真なら1、偽なら0）

確率の導出

$$P(Y=1|X) = P(Y^* > 0|X) = P(X'\beta + U > 0) = P(U > -X'\beta)$$

標準正規分布の対称性より：

$$= P(U < X'\beta) = \Phi(X'\beta)$$

→ やはりプロビットモデルが導出される！

4.3 両アプローチの関係

- 確率的効用モデルの $U_1 - U_0$ を Y^* と解釈
- β^* を直接的な β と見なす
- 本質的に同じモデルを異なる視点から見ている

4.4 潜在変数モデルの適用例

所得と貧困状態：

- Y^*（所得そのもの）は観測できない
- しかし「貧困状態にあるかどうか」（政府からの支給を受けているか）は観測可能
- このようなデータに潜在変数モデルが適用可能

---

5. 係数の解釈に関する重要な注意点

5.1 係数の大きさ自体に意味はない

確率的効用モデルの導出過程で：

$$\beta^* = \frac{\beta_1 - \beta_0}{\sigma_{\varepsilon_1}}$$

- 係数は誤差項の標準偏差で割られている
- したがって、係数の符号（正負）は意味があるが、大きさ自体は解釈できない
- プロビット・ロジット・線形確率モデル間で係数を直接比較することはできない

5.2 係数の経済学的解釈

β^* は「2つの選択肢それぞれから来る効用に与える影響の差」として解釈可能

---

6. 分散不均一性（Heteroskedasticity）

6.1 第1の意味：構造的な分散不均一

プロビットモデルでの条件付き分散

$$Var(Y|X) = \Phi(X'\beta)[1 - \Phi(X'\beta)]$$

導出

条件付き分散の定義より：$$Var(Y|X) = E[(Y - E[Y|X])^2|X]$$

Y は0か1しか取らないので $Y^2 = Y$ という性質を利用：

$$= E[Y|X] - (E[Y|X])^2 = \Phi \cdot (1 - \Phi)$$

重要な結論

- プロビット・ロジット・線形確率モデルは自動的に分散不均一
- 分散が X に依存する形になっている
- しかもその形が特定の構造（$\Phi(1-\Phi)$）を持つ

線形確率モデルでの問題

- Φ の代わりに $X'\beta$ そのものが入る
- $X'\beta$ が0〜1の外に出ると、分散が負になる可能性
- 分散が負だと標準誤差（√分散）が計算できない（複素数になる）
- 検定が不可能になる

6.2 第2の意味：潜在変数モデルでの誤差項の分散不均一

標準的な設定

$$Y^* = X'\beta + U, \quad U \sim N(0,1)$$

- 誤差項 U は分散1の標準正規分布
- この仮定のもとで通常のプロビット推定が正当化される

もし誤差項が分散不均一だったら？

$$U_i \sim N(0, \sigma^2(X_i))$$

分散が X に依存する場合：

$$P(Y=1|X) = \Phi\left(\frac{X'\beta}{\sigma(X)}\right)$$

- 通常のプロビット推定では β を識別できなくなる
- $\beta/\sigma(X)$ という比率しか推定できない

対処法

$\sigma(X)$ をパラメトリックに指定：

例：$\sigma(X) = \exp(\gamma' X)$

これを代入して β と γ を同時推定

結論

- 誤差項が分散不均一だと、通常のプロビット推定は一致性を失う
- この問題に対処するには、分散構造を明示的にモデル化する必要がある

第2部：時系列分析（Time Series Analysis）

7. クロスセクションデータとの違い

7.1 データの性質

	クロスセクション	時系列
対象	異なる個人・企業	同一対象を時間で追跡
独立性	i.i.d.を仮定可能	時点間で相関あり
例	100人の身長体重	1人を100日間追跡

7.2 時系列データの特徴

- 近い時点のデータは相関が高い
- 離れた時点のデータは相関が低い（かもしれない）
- この「時間を通じた相関」＝系列相関（**Serial Correlation**）

7.3 時系列データの例

- GDP、金利、貿易などのマクロデータ（年次・四半期）

- 株価、為替レート（高頻度データ：分単位、秒単位）

7.4 記法

- Y_t：時点 t における変数の値
- $t = 1, 2, ..., T$（T がサンプルサイズ）
- Y_{t-j}：j 期前の値（Y_t の j 次ラグ）

---

8. 定常性（Stationarity）

8.1 なぜ定常性が必要か

- クロスセクションでは i.i.d. を仮定
- 時系列で同様の仮定を置かないと統計分析ができない
- 定常性はデータ生成構造に対する「縛り」

8.2 強定常性（Strict Stationarity）の定義

同時分布が時間を通じて変わらない

具体的には：

- 任意の時点の組 $(Y_{t_1}, Y_{t_2}, ..., Y_{t_k})$ の同時分布
- 時点をすべて同じだけずらした $(Y_{t_1+h}, Y_{t_2+h}, ..., Y_{t_k+h})$ の同時分布
- これらがすべての **h** について同一

例：**2**変数の場合

- (Y_1, Y_2) の同時分布
- (Y_2, Y_3) の同時分布
- (Y_5, Y_6) の同時分布
- すべて同じ

さらに

- 「隣り合う2つ」だけでなく「1つ飛ばしの2つ」も
- (Y_1, Y_3) と (Y_2, Y_4) と (Y_5, Y_7) も同じ
- 任意の個数、任意のラグ構造で成立

8.3 弱定常性（Weak Stationarity）の定義

以下の3条件が成り立つとき：

1. 期待値が時点に依存しない：$E[Y_t] = \mu$（すべての t で同じ）
2. 分散が時点に依存しない：$Var(Y_t) = \gamma_0$（すべての t で同じ）
3. 自己共分散がラグのみに依存：$Cov(Y_t, Y_{t-j}) = \gamma_j$
    - t には依存せず、j（ラグ）のみに依存

別名：共分散定常性（**Covariance Stationarity**）、**2**次定常性

8.4 強定常と弱定常の関係

関係	成立？
強定常 → 弱定常	○（モーメントが存在すれば）
弱定常 → 強定常	×（反例あり）

反例：

- Y_1 は正規分布、Y_2 は指数分布
- 期待値・分散・自己共分散は同じでも同時分布が異なる

注意：強定常でもモーメントが存在しない場合（例：コーシー分布）は弱定常にならない

8.5 ホワイトノイズ（**White Noise**）

定義：

- 期待値 = 0
- 分散 = σ^2（一定）
- すべての $j \neq 0$ について $\gamma_j = 0$（自己相関なし）

特徴：

- 弱定常の特殊ケース
- 時点間の相関が全くない
- 「ほぼクロスセクションデータと同じ」と言える

---

9. 非定常性の例

9.1 トレンドがある場合

```
  *
  *  *
 *    *
*      *
*       * ...（上昇トレンド）
```

- 期待値が時点によって異なる
- $E[Y_t] \neq \mu$（時点 t に依存）
- 弱定常の条件①を満たさない

9.2 分散が変動する場合（ボラティリティ・クラスタリング）

```
安定期：～～～～
激動期：∿∿∿∿∿∿（大きな変動）
安定期：～～～～
```

- 金融データでよく見られる
- ある時期は分散が小さく、別の時期は分散が大きい
- 弱定常の条件②を満たさない

9.3 構造変化（Structural Break）

```
   |
～～～～|^^^^^^
    |
  政策変更
```

- ある時点で期待値や分散が急変
- 例：政策変更、制度改革
- 定常性が崩れる典型例

---

10. 自己相関関数（Autocorrelation Function: ACF）

10.1 自己共分散（Autocovariance）

$$\gamma_j = Cov(Y_t, Y_{t-j})$$

- $\gamma_0 = Var(Y_t)$（$j=0$ のとき）
- 定常性の下では t に依存せず j のみに依存

10.2 自己相関係数（Autocorrelation Coefficient）

$$\rho_j = \frac{\gamma_j}{\gamma_0} = \frac{Cov(Y_t, Y_{t-j})}{\sqrt{Var(Y_t)} \cdot \sqrt{Var(Y_{t-j})}}$$

定常性より $Var(Y_t) = Var(Y_{t-j}) = \gamma_0$ なので：

$$\rho_j = \frac{\gamma_j}{\gamma_0}$$

性質：

- $\rho_0 = 1$（常に）
- $-1 \leq \rho_j \leq 1$
- 対称性：$\rho_j = \rho_{-j}$

10.3 標本自己共分散・自己相関係数

$$\hat{\gamma}*j = *frac{1}{T}* *sum*{t=j+1}^{T} (Y_t - \bar{Y})(Y_{t-j} - \bar{Y})$$

$$\hat{\rho}_j = \frac{\hat{\gamma}_j}{\hat{\gamma}_0}$$

注意：$\hat{\gamma}_j$ の計算では、j 期分のデータが使えなくなる

10.4 コレログラム（Correlogram）

- 横軸：ラグ j
- 縦軸：$\hat{\rho}_j$
- 時系列データの相関構造を視覚化

```
ρ
1|*
 |  *
 |    *
 |      *
 |------------ (信頼区間)
0|----------*---*---*---
 |------------
 0  1  2  3  4  5  6  j
```

10.5 信頼区間（漸近分布）

i.i.d. データの場合、$\hat{\rho}_j$ は近似的に：

$$\hat{\rho}_j \sim N\left(0, \frac{1}{T}\right)$$

したがって、95%信頼区間は:

$$\pm \frac{1.96}{\sqrt{T}}$$

コレログラムにこの線を引き、自己相関が有意かどうかを視覚的に判断

---

11. ポートマンテスト（Portmanteau Test）

11.1 目的

「この時系列は自己相関を持っているか？」をまとめて検定

11.2 帰無仮説

$$H_0: \rho_1 = \rho_2 = ... = \rho_P = 0$$

すべての自己相関係数が0（＝ホワイトノイズ）

11.3 Box-Pierce統計量

$$Q_{BP} = T \sum_{k=1}^{P} \hat{\rho}_k^2$$

11.4 Ljung-Box統計量（修正版）

$$Q_{LB} = T(T+2) \sum_{k=1}^{P} \frac{\hat{\rho}_k^2}{T-k}$$

- Box-Pierceの小標本修正版
- より正確な検定が可能

11.5 漸近分布

帰無仮説の下で:

$$Q \xrightarrow{d} \chi^2(P)$$

解釈:

- Q が大きい → 自己相関あり → H_0 を棄却
- Q が小さい → 自己相関なし → H_0 を採択

11.6 P の選び方

- あまり大きくできない

- $\hat{\rho}_P$ の計算に P 期分のデータが必要
- P を T に近づけると精度が落ちる
- 実務上：$P = 10$ 程度（目安）

11.7 検定の使い方

1. まず自己相関の有無を検定
2. 自己相関なし → クロスセクション的に扱える
3. 自己相関あり → 時系列モデル（ARMAなど）を適用

---

12. 自己回帰モデル（AR Model）

12.1 AR(1)モデル

$$Y_t = \alpha_0 + \alpha_1 Y_{t-1} + U_t$$

- 現在の値 = 定数 + 1期前の値×係数 + ノイズ
- U_t：ホワイトノイズ（または i.i.d.）
- 「自分自身の過去の値で回帰」→ 自己回帰

用語：

- U_t は「誤差項」「ノイズ」「イノベーション」とも呼ばれる

12.2 AR(p)モデル（一般化）

$$Y_t = \alpha_0 + \alpha_1 Y_{t-1} + \alpha_2 Y_{t-2} + ... + \alpha_p Y_{t-p} + U_t$$

- p 期前までの値を説明変数として使用
- p は「次数（order）」

12.3 回帰モデルとしての解釈

$$Y_t = X'_t \beta + U_t$$

ここで $X_t = (1, Y_{t-1}, ..., Y_{t-p})'$

- 通常の回帰モデルと同じ構造
- ただし説明変数が「自分自身の過去の値」
- $E[U_t | Y_{t-1}, ..., Y_{t-p}] = 0$ なら外生性が成立

12.4 分散不均一への対応

- 時系列では分散不均一がより複雑
- **ARCH**モデル、**GARCH**モデルで分散構造をモデル化
- 特に金融データで重要

---

13. AR(1)モデルの定常性条件

13.1 特性方程式

$$1 - \alpha_1 z = 0$$

の解 $z = 1/\alpha_1$ について、$|z| > 1$ であること

13.2 等価な条件

$$|\alpha_1| < 1$$

解釈:

- $|\alpha_1| < 1$:過去のショックの影響が減衰 → 安定
- $|\alpha_1| \geq 1$:過去のショックの影響が持続・増幅 → 不安定

13.3 直感的理解

- $\alpha_1 = 0.9$:昨日の値の90%が今日に影響 → 徐々に減衰
- $\alpha_1 = 1.0$:ランダムウォーク → 非定常
- $\alpha_1 = 1.1$:発散 → 非定常

---

14. AR(2)モデルの定常性条件

14.1 特性方程式

$$1 - \alpha_1 z - \alpha_2 z^2 = 0$$

この2次方程式の両方の解について $|z| > 1$

14.2 パラメータ空間での条件

$$\alpha_1 + \alpha_2 < 1$$ $$\alpha_2 - \alpha_1 < 1$$ $$|\alpha_2| < 1$$

これらを満たす (α_1, α_2) の領域は三角形になる

---

15. 推奨文献

講義で言及された参考書:

- **Hamilton (1994)** "Time Series Analysis"
  - 時系列分析の標準的テキスト
  - 定常性の厳密な定義、漸近理論の詳細

📋 重要ポイントまとめ

二値選択モデル

モデル	式	問題点
線形確率	$P(Y=1 \| X) = X'\beta$	
プロビット	$P(Y=1 \| X) = \Phi(X'\beta)$	
ロジット	$P(Y=1 \| X) = \Lambda(X'\beta)$	

時系列分析

概念	内容
強定常	同時分布が時点に依存しない
弱定常	期待値・分散・自己共分散が時点に依存しない
自己相関	$\rho_j = \gamma_j / \gamma_0$
ポートマンテスト	「すべての自己相関=0」をまとめて検定
AR(p)	$Y_t = \alpha_0 + \sum_{i=1}^p \alpha_i Y_{t-i} + U_t$
定常性条件（AR1）	$

📅 今後の予定（講義より）

- 年明け1月5日（月）：授業再開
- 成人の日の週：休み
- 1月最終月曜日：期末試験
- 練習問題が年明け早々に配布予定